學號：B04902097 系級： 資工二 姓名：陳家棋

## 1. (1%) 請比較有無 normalize(rating) 的差別。並說明如何 normalize.

normalize 方法：取 training data rating 的 mean 和 std，將 training data rating 減掉 mean 後除以 std 拿去 train model，最後 predict 出來的值乘上 std 再加 mean。(mean、std 皆為取自 training rating)

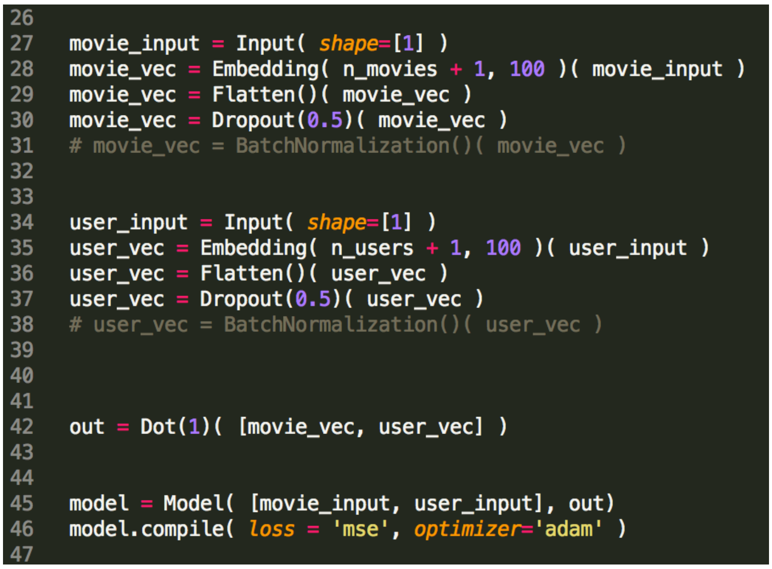

```

movie_input = Input( shape=[1] )
movie_vec = Embedding( n_movies + 1, 100 )( movie_input )
movie_vec = Flatten()( movie_vec )
movie_vec = Dropout(0.5)( movie_vec )
# movie_vec = BatchNormalization()( movie_vec )


user_input = Input( shape=[1] )
user_vec = Embedding( n_users + 1, 100 )( user_input )
user_vec = Flatten()( user_vec )
user_vec = Dropout(0.5)( user_vec )
# user_vec = BatchNormalization()( user_vec )



out = Dot(1)( [movie_vec, user_vec] )


model = Model( [movie_input, user_input], out)
model.compile( loss = 'mse', optimizer='adam' )

```

| | 有 BatchNormalization | | 無 BatchNormalization | |
|---|---|---|---|---|
| | 無 normalize | 有 normalize | 無 normalize | 有 normalize |
| kaggle score | 0.84720 | 0.84786 | 0.88208 | 0.84877 |

我發現在沒加 BatchNormalization 前，對 rating 做 normalize 的處理會提高準確度，但加了 BatchNormalization 後則差異不大。故做 normalization 能提高準確度。

## 2. (1%) 比較不同的 latent dimension 的結果。

| dimension | 50 | 100 | 150 | 200 | 250 | 300 |
|---|---|---|---|---|---|---|
| kaggle score | 0.85221 | 0.84720 | 0.84666 | 0.84795 | 0.85039 | 0.85085 |

我發現約150的時候效果最佳。

### 3. (1%) 比較有無 bias 的結果。

我做了兩種 bias。第一種是多加一個 embedding 到 1 維，第二種是拿用來做內積的 100 維 embedding dense 到 1 維。兩者效果看似差不多。有無 bias 對 kaggle score 來說差異不大。(無 bias : 0.84666)

| | embedding | dense |
|---|---|---|
| kaggle score | 0.84647 | 0.84673 |

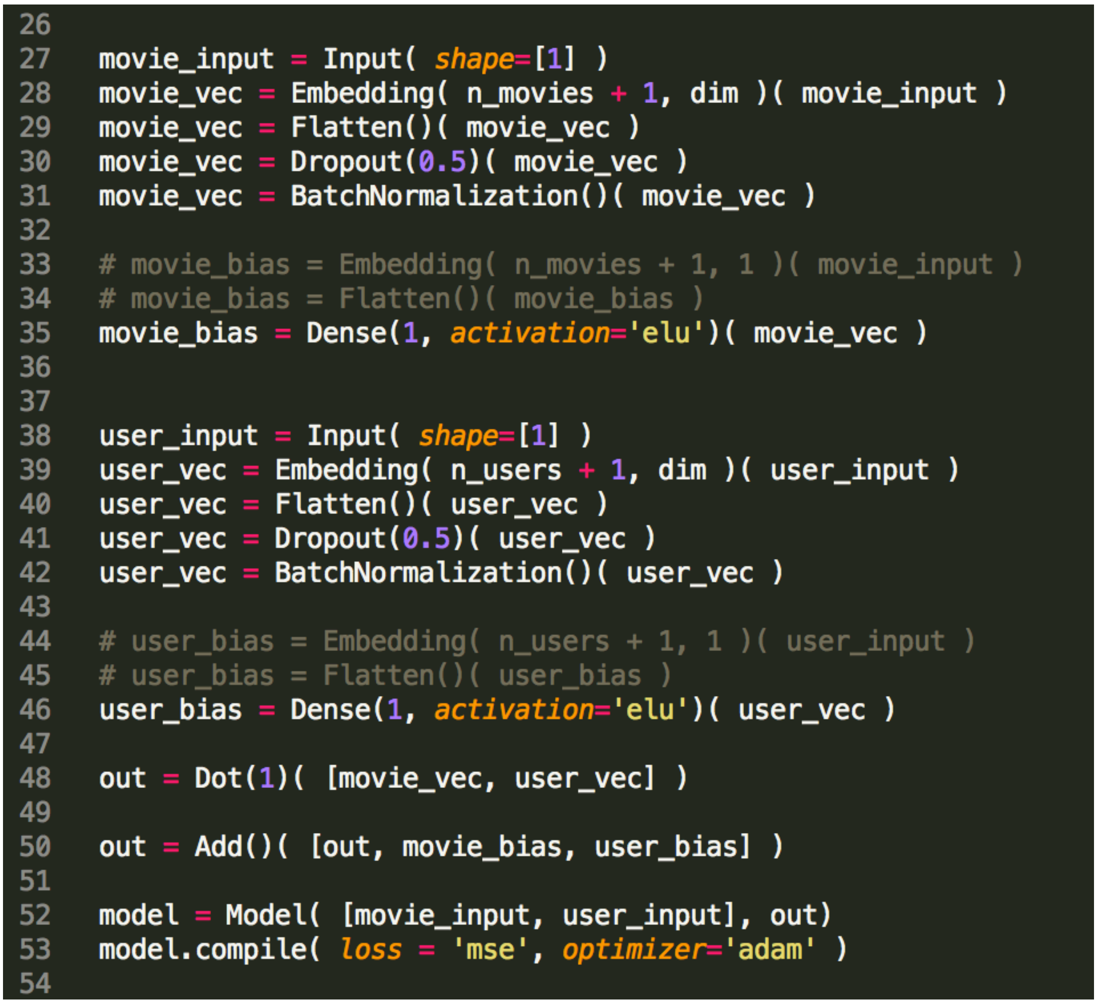

```
movie_input = Input( shape=[1] )
movie_vec = Embedding( n_movies + 1, dim )( movie_input )
movie_vec = Flatten()( movie_vec )
movie_vec = Dropout(0.5)( movie_vec )
movie_vec = BatchNormalization()( movie_vec )

# movie_bias = Embedding( n_movies + 1, 1 )( movie_input )
# movie_bias = Flatten()( movie_bias )
movie_bias = Dense(1, activation='elu')( movie_vec )


user_input = Input( shape=[1] )
user_vec = Embedding( n_users + 1, dim )( user_input )
user_vec = Flatten()( user_vec )
user_vec = Dropout(0.5)( user_vec )
user_vec = BatchNormalization()( user_vec )

# user_bias = Embedding( n_users + 1, 1 )( user_input )
# user_bias = Flatten()( user_bias )
user_bias = Dense(1, activation='elu')( user_vec )

out = Dot(1)( [movie_vec, user_vec] )

out = Add()( [out, movie_bias, user_bias] )

model = Model( [movie_input, user_input], out)
model.compile( loss = 'mse', optimizer='adam' )

```

**4. (1%) 請試著用 DNN 來解決這個問題，並且說明實做的方法(方法不限)。並比較 MF 和 NN 的結果，討論結果的差異。**

我做出來 MF 的效果比 DNN 來的要好，我認為這樣的差距應該只是參數沒調好造成，DNN 應該可以有相當於 MF 的表現。

| | MF | DNN |
|---|---|---|
| kaggle score | 0.84720 | 0.86196 |

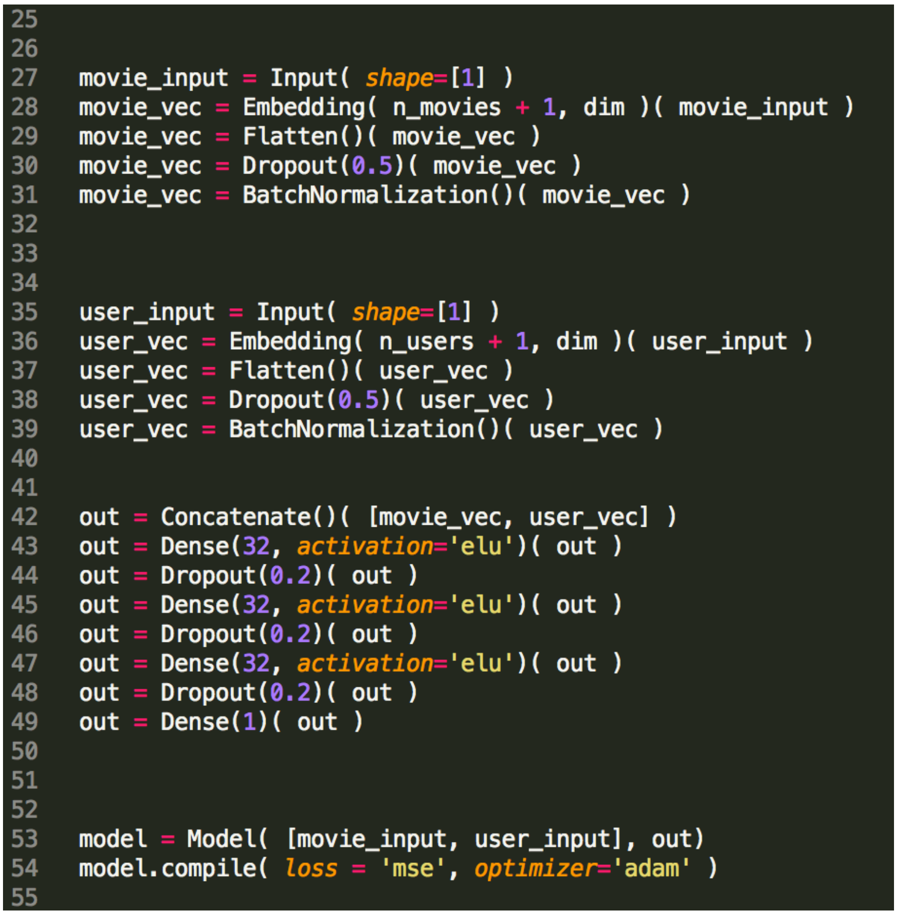

```
movie_input = Input( shape=[1] )
movie_vec = Embedding( n_movies + 1, dim )( movie_input )
movie_vec = Flatten()( movie_vec )
movie_vec = Dropout(0.5)( movie_vec )
movie_vec = BatchNormalization()( movie_vec )



user_input = Input( shape=[1] )
user_vec = Embedding( n_users + 1, dim )( user_input )
user_vec = Flatten()( user_vec )
user_vec = Dropout(0.5)( user_vec )
user_vec = BatchNormalization()( user_vec )


out = Concatenate()( [movie_vec, user_vec] )
out = Dense(32, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(32, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(32, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(1)( out )



model = Model( [movie_input, user_input], out)
model.compile( loss = 'mse', optimizer='adam' )
```

**5. (1%) 請試著將 movie 的 embedding 用 tsne 降維後，將 movie category 當作 label 來作圖。**

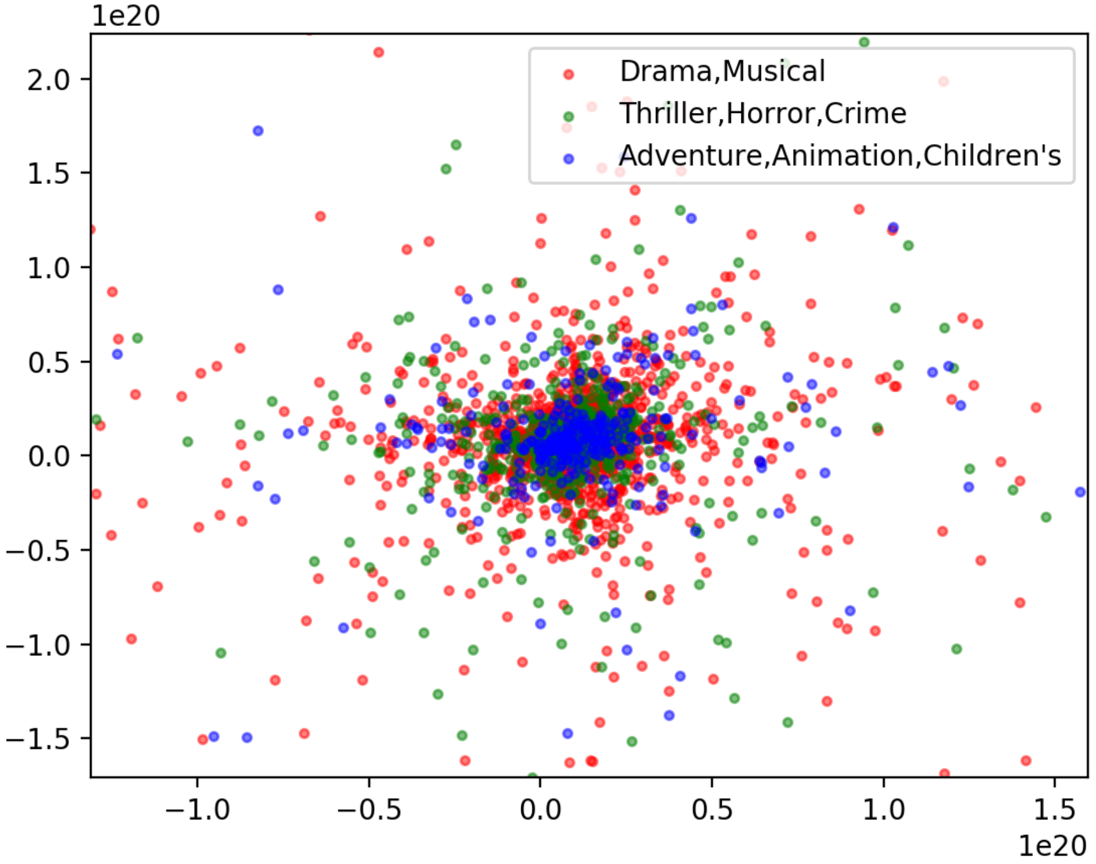

**6. (BONUS) (1%) 試著使用除了 rating 以外的 feature, 並說明你的作法和結果，結果好壞不會影響評分。**

我將 users.csv 中的 Gender、Age、Occuaption 做 1 of n encoding，再將 movies.csv 中的 Genres 做 1 of n encoding，training 時與 embedding 後的結果 concatenate 起來做 DNN。最後上傳 kaggle 分數只有 0.97 左右。

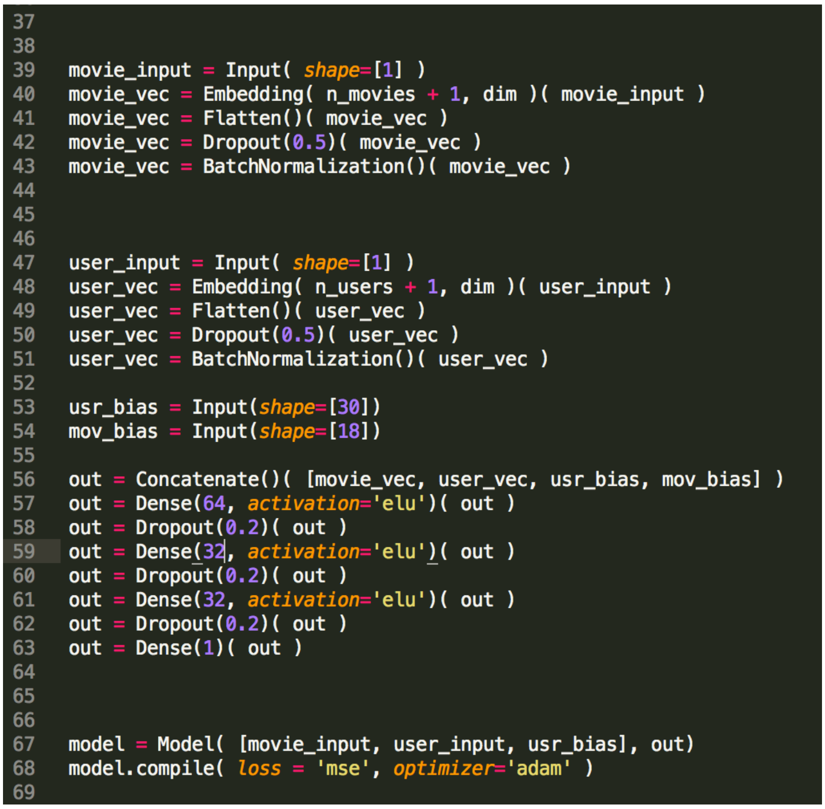

```python


movie_input = Input( shape=[1] )
movie_vec = Embedding( n_movies + 1, dim )( movie_input )
movie_vec = Flatten()( movie_vec )
movie_vec = Dropout(0.5)( movie_vec )
movie_vec = BatchNormalization()( movie_vec )



user_input = Input( shape=[1] )
user_vec = Embedding( n_users + 1, dim )( user_input )
user_vec = Flatten()( user_vec )
user_vec = Dropout(0.5)( user_vec )
user_vec = BatchNormalization()( user_vec )

usr_bias = Input(shape=[30])
mov_bias = Input(shape=[18])

out = Concatenate()( [movie_vec, user_vec, usr_bias, mov_bias] )
out = Dense(64, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(32, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(32, activation='elu')( out )
out = Dropout(0.2)( out )
out = Dense(1)( out )



model = Model( [movie_input, user_input, usr_bias], out)
model.compile( loss = 'mse', optimizer='adam' )

```